

Guía paso a paso: Limpieza y Árbol de Decisión en Weka

Objetivo

Limpiar el dataset diabetes.arff, entrenar un clasificador J48 y visualizar el árbol de decisión resultante el antes y después.

PARTE 1: Limpieza del Dataset

Paso 1: Abrir Weka


Ejecuta Weka 3.8.7 y selecciona Explorer.

Haz clic en la pestaña Preprocess.

Paso 2: Cargar el dataset

Clic en Open file... y selecciona diabetes.arff.


Verifica que aparezcan 768 instancias y 9 atributos.



Paso 3: Detectar valores inválidos (ceros)

Haz clic en cada atributo: plas, pres, skin, insu, mass.

Observa el histograma: verás una barra alta en el valor 0 (imposible médicamente).





Paso 4: Reemplazar ceros por valores faltantes

En el panel Filter, clic en Choose.

Navega a: `weka.filters.unsupervised.attribute.NumericCleaner`.

Clic sobre el nombre del filtro para configurar:


- attributeIndices: 2-6
- minThreshold: 0.1
- minDefault: NaN
- maxThreshold: (dejar vacío)
- Clic en Apply.



Paso 5: Reemplazar valores faltantes por la media

En Filter → Choose → weka.filters.unsupervised.attribute.ReplaceMissingValues.

Clic en Apply.



Esto reemplaza los ? con la media de cada columna.

Paso 6: Guardar el dataset limpio

Clic en Save... y guarda como diabetes_limpio.arff.

PARTE 2: Entrenar y visualizar el árbol con J48


Paso 7: Ir a la pestaña Classify

Clic en la pestaña Classify en la parte superior.

Paso 8: Seleccionar el clasificador J48

Clic en Choose.

Navega a: trees → J48.



Respuesta

=== Run information ===

Scheme: weka.classifiers.trees.J48 -C 0.25 -M 2

Relation: pima_diabetes-weka.filters.unsupervised.attribute.NumericCleaner-min0.1-min-defaultNaN-max1.7976931348623157E308-max-default1.7976931348623157E308-closeto0.0-closeto-default0.0-closeto-tolerance1.0E-6-R2-6-decimals-1-weka.filters.unsupervised.attribute.ReplaceMissingValues

Instances: 768

Attributes: 9

preg

plas

pres

skin

insu

mass

pedi

age

class

Test mode: split 80.0% train, remainder test

=== Classifier model (full training set) ===

J48 pruned tree

plas <= 127

```

| mass <= 26.4: tested_negative (122.0/1.0)
| mass > 26.4
| | age <= 28: tested_negative (188.0/22.0)
| | age > 28
| | | insu <= 88: tested_negative (22.0)
| | | insu > 88
| | | | pedi <= 0.624
| | | | | plas <= 93: tested_negative (22.0/1.0)
| | | | | plas > 93
| | | | | | age <= 54
| | | | | | | skin <= 32
| | | | | | | | pres <= 82: tested_positive (52.0/18.0)
| | | | | | | | pres > 82
| | | | | | | | | pedi <= 0.395: tested_negative (11.0/1.0)
| | | | | | | | | pedi > 0.395: tested_positive (2.0)
| | | | | | | | | skin > 32
| | | | | | | | | pres <= 88: tested_negative (19.0/3.0)
| | | | | | | | | pres > 88: tested_positive (2.0)
| | | | | | | | | age > 54: tested_negative (8.0)
| | | | | | | | | pedi > 0.624: tested_positive (37.0/9.0)
| plas > 127
| | mass <= 29.9
| | | plas <= 145: tested_negative (40.0/6.0)
| | | plas > 145
| | | | insu <= 150: tested_positive (8.0/1.0)
| | | | insu > 150
| | | | | preg <= 1: tested_negative (5.0)
| | | | | preg > 1
| | | | | | pedi <= 0.18: tested_positive (3.0)
| | | | | | pedi > 0.18
| | | | | | | age <= 53
| | | | | | | | preg <= 7
| | | | | | | | | pres <= 72.405184: tested_positive (6.0/1.0)
| | | | | | | | | pres > 72.405184: tested_negative (6.0)
| | | | | | | | | preg > 7: tested_positive (3.0)
| | | | | | | | | age > 53: tested_negative (4.0)
| | mass > 29.9
| | | plas <= 157
| | | | preg <= 7
| | | | | pres <= 61: tested_positive (6.0)
| | | | | pres > 61
| | | | | | insu <= 192: tested_positive (65.0/26.0)
| | | | | | insu > 192
| | | | | | | age <= 42: tested_negative (16.0/1.0)
| | | | | | | age > 42: tested_positive (3.0)
| | | | | | | | preg > 7
| | | | | | | | | pedi <= 0.43
| | | | | | | | | | pres <= 74: tested_positive (3.0)

```

```
| | | | | pres > 74: tested_negative (5.0/1.0)
| | | | | pedi > 0.43: tested_positive (18.0/1.0)
| | | plas > 157: tested_positive (92.0/12.0)
```

Number of Leaves : 27

Size of the tree : 53

Time taken to build model: 0.02 seconds

=== Evaluation on test split ===

Time taken to test model on test split: 0 seconds

=== Summary ===

Correctly Classified Instances	116	75.3247 %
Incorrectly Classified Instances	38	24.6753 %
Kappa statistic	0.425	
Mean absolute error	0.3127	
Root mean squared error	0.4446	
Relative absolute error	69.7837 %	
Root relative squared error	95.113 %	
Total Number of Instances	154	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.829	0.408	0.813	0.829	0.821	0.425	0.780	0.865	tested_negative
	0.592	0.171	0.617	0.592	0.604	0.425	0.780	0.553	tested_positive
Weighted Avg.	0.753	0.333	0.751	0.753	0.752	0.425	0.780	0.766	


=== Confusion Matrix ===

```
a b <-- classified as
87 18 | a = tested_negative
20 29 | b = tested_positive
```

Paso 9: Visualizar el árbol de decisión

En el panel Result list (izquierda), haz clic derecho sobre el resultado trees.J48.

Selecciona Visualize tree.



Paso 13: Interpretar el árbol

El nodo raíz es ser plas (glucosa en plasma).


Cada rama muestra una condición (ej: plas <= 127).

Las hojas indican la clase predicha: tested_negative o tested_positive.


Los números entre paréntesis indican: (instancias_clasificadas / instancias_incorrectas).

PARTE 3: comparación con el dataset sin limpiar

Datos sin limpiar



Árbol sin limpiar



Datos de la comparación:

- El nodo raíz no cambió: plas (glucosa) sigue siendo el predictor más importante. Esto tiene sentido médico: la glucosa es el principal indicador de diabetes.
- La limpieza eliminó ruido: Los ceros imposibles creaban ramas falsas. Al imputarlos con la media, el árbol aprendió patrones más realistas.
- Mejora ligera pero significativa: El accuracy subió ~1-2%, el Kappa mejoró y los errores disminuyeron. No es un cambio enorme, pero sí confirma que la limpieza ayudó.
- Hojas más puras: En el árbol limpio, muchas hojas tienen 0 o 1 error (ej: `tested_negative (122.0/1.0)`), lo que indica que el modelo clasifica mejor.
- La división principal se mantiene: $\text{plas} \leq 127$ vs $\text{plas} > 127$ sigue siendo el corte más discriminante.